

Analisi comparativa di Q-Networks Profonde Classiche e di Circuiti Quantistici Parametrizzati per compiti di Apprendimento per Rinforzo.

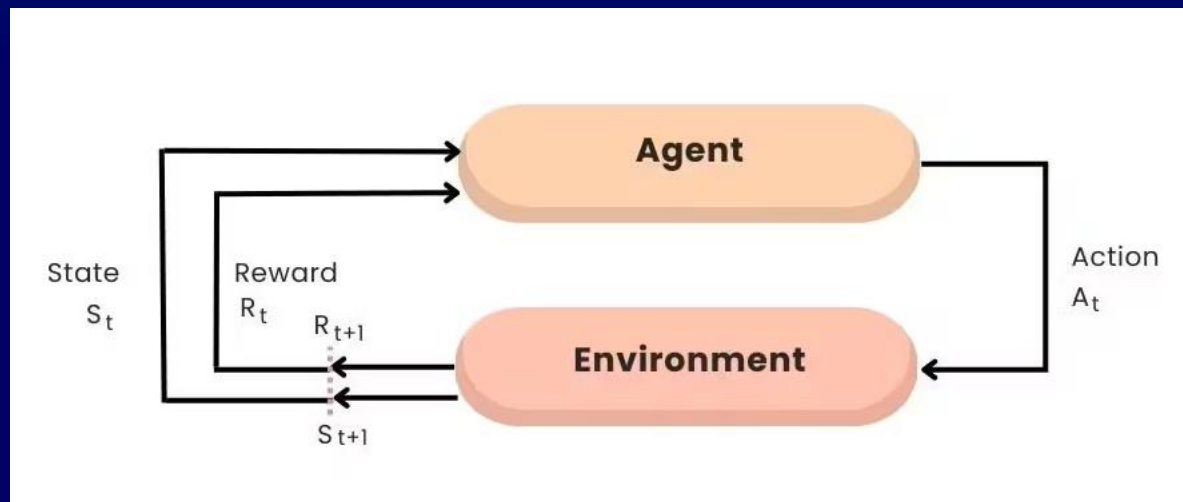
Candidato:
Francesco Farabegoli

Relatore:
Prof. Andrea Giachero

Co-relatore:
Dott. Danilo Labranca

Apprendimento per Rinforzo

- Imparare dall'esperienza è fondamentale per affrontare problemi complessi: ci aiuta a riconoscere schemi e prendere decisioni informate guidando le nostre azioni verso il raggiungimento di un obiettivo.
- Questo principio è alla base dell'Apprendimento per Rinforzo (Reinforcement Learning), uno dei campi più innovativi e dinamici del Machine Learning.
- Trova diverse applicazioni nel campo della fisica, ad esempio per determinare stati fondamentali di sistemi quantistici oppure progettare sequenze di controllo per i Qubit.



Quantum Machine Learning

Possono le proprietà dei Qubit rendere l'apprendimento più efficiente?

OBIETTIVO

L'obiettivo principale di questo lavoro di tesi è valutare se e come l'integrazione del calcolo quantistico in algoritmi di Reinforcement Learning possa migliorarne l'efficienza.


Per testare se il Quantum Machine Learning possa superare le tecniche tradizionali, ho implementato un algoritmo di RL che sostituisce alla Rete Neurale Classica, un Circuito Quantistico Parametrizzato (PQC).

I codici sono stati adattati da tutorial ufficiali di **TensorFlow***.

**<https://www.tensorflow.org/>*


Ambiente di test e algoritmo utilizzato

- Entrambi gli algoritmi sono stati testati in un ambiente di OpenAI Gym* chiamato Acrobot-v1.
- L'agente deve applicare un momento torcente alla giunzione inferiore con una giusta coordinazione per fare oscillare il sistema al di sopra di una determinata altezza obiettivo.




Ambiente di test e algoritmo utilizzato

- Entrambi gli algoritmi sono stati testati in un ambiente di OpenAI Gym* chiamato Acrobot-v1.
- L'agente deve applicare un momento torcente alla giunzione inferiore con una giusta coordinazione per fare oscillare il sistema al di sopra di una determinata altezza obiettivo.



Ambiente di test e algoritmo utilizzato

- Entrambi gli algoritmi sono stati testati in un ambiente di OpenAI Gym* chiamato Acrobot-v1.
- L'agente deve applicare un momento torcente alla giunzione inferiore con una giusta coordinazione per fare oscillare il sistema al di sopra di una determinata altezza obiettivo.



- Entrambi i metodi utilizzano il deep Q-learning il cui obiettivo è imparare la funzione di valore d'azione, Q_{π} , che fornisce il ritorno atteso per l'esecuzione di una specifica azione a nello stato s , assumendo che l'agente segua una data politica π .

$$Q_{\pi}(s, a) = E_{\pi}[G_t | s_t = s, a_t = a]$$


*<https://www.gymnasium.dev>

Reti Neurali Profonde VS Circuiti Quantistici Parametrizzati

Intelligenza Artificiale Classica e Quantistica a Confronto

Reti Neurali Profonde

- Una Rete Neurale è un modello di Machine Learning composto da nodi (neuroni) organizzati in tre diversi tipi di strati.
- Ogni connessione tra un neurone in uno strato e un neurone nel successivo ha un peso.
- Questi pesi vengono regolati per migliorare la capacità della rete di fornire risultati accurati.




Qubit

- I Qubit sono l'unità fondamentale del calcolo quantistico e i Circuiti Quantistici Parametrizzati sfruttano le loro proprietà per la computazione.
- Possono esistere simultaneamente negli stati $|0\rangle$ e $|1\rangle$ grazie alla sovrapposizione e consentono una profonda connessione tramite l'entanglement.

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$$

Lo stato $|\psi\rangle$ di un Qubit può essere visualizzato attraverso uno strumento grafico, la sfera di Bloch.

$$|\Psi\rangle = \cos(\theta/2) + e^{i\varphi} \sin(\theta/2)$$



Qubit


- I Qubit sono l'unità fondamentale del calcolo quantistico e i Circuiti Quantistici Parametrizzati sfruttano le loro proprietà per la computazione.
- Possono esistere simultaneamente negli stati $|0\rangle$ e $|1\rangle$ grazie alla sovrapposizione e consentono una profonda connessione tramite l'entanglement.

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$$

Lo stato $|\psi\rangle$ di un Qubit può essere visualizzato attraverso uno strumento grafico, la sfera di Bloch.

$$|\Psi\rangle = \cos(\theta/2) + e^{i\varphi} \sin(\theta/2)$$

Esso può essere modificato tramite l'applicazione di Gates Quantistici, analoghi alle porte logiche utilizzate su bit classici.



Circuiti Quantistici Parametrizzati

➤ I Circuiti Quantistici Parametrizzati, sequenze di gates fissi e variazionali applicati ad un insieme di Qubit, prevedono i Q-valori attesi per le azioni intraprese in diversi stati.

➤ Si compongono di 4 passi fondamentali:

1. Preparazione dello stato:


$$|x\rangle = \bigotimes_{i=0}^{n-1} R_a(\varphi(x_i \cdot \lambda_i)) |0_i\rangle$$

2. Processazione variazionale

3. Misura e decodifica degli output:

$$Q(s, a) = \langle 0^n | U_{\theta}^s(x)^\dagger O_a U_{\theta}^s(x) | 0^n \rangle$$

4. Ottimizzazione dei parametri




Raccolta ed analisi dati

- La comparativa è stata effettuata osservando la performance degli agenti al variare di 3 parametri fondamentali comuni ad entrambi gli approcci.
- La performance degli agenti è stata valutata tramite il trend delle ricompense su un intervallo di episodi.
- L'algoritmo quantistico è eseguito su Qubit ideali, eliminando ogni fonte di errore che verrebbe a presentarsi se il circuito venisse eseguito su computer quantistici reali.

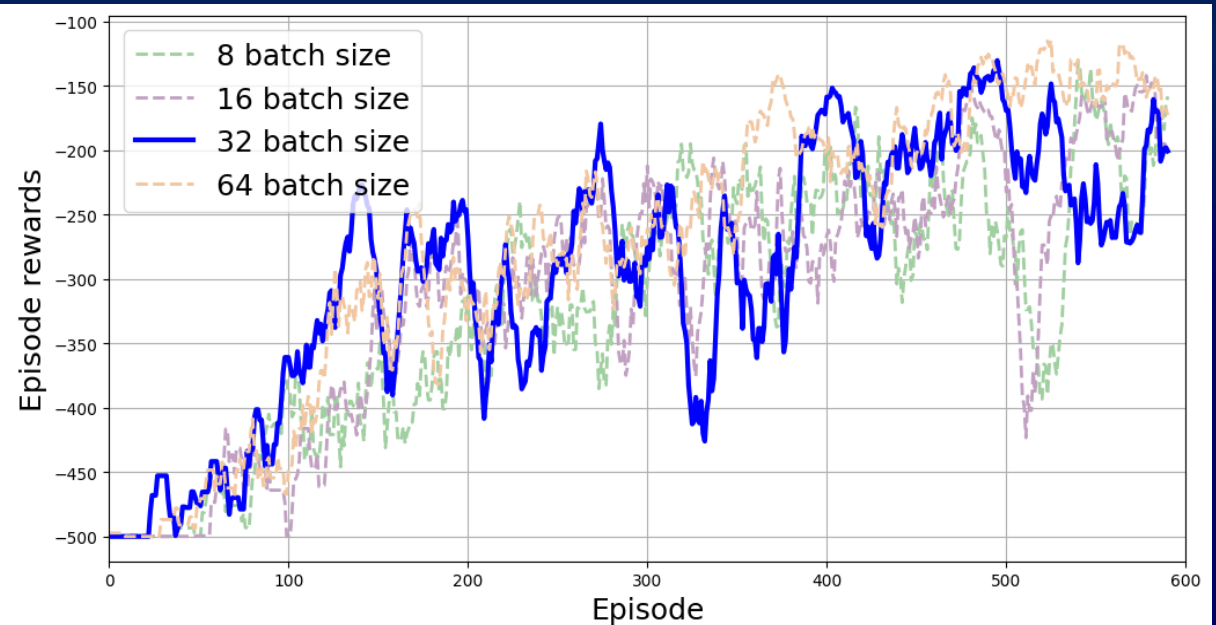
Variazioni della dimensione del Batch

Variazione del numero di traiettorie (s_t, a_t, r_t, s_{t+1}) che l'agente campiona durante la fase di training e con le quali aggiorna i Q-valori.

RUN CLASSICA




RUN QUANTISTICA




Variazioni dell'architettura della Rete Neurale e del PQC

Variazione del numero di neuroni negli strati computazionali nascosti per la rete classica e del numero di strati variazionali per il PQC.

RUN CLASSICA



RUN QUANTISTICA




Variazioni del Tasso di Apprendimento


Variazione di un parametro fondamentale che guida l'aggiornamento dei Q-valori:

$$Q'(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$$

RUN CLASSICA



RUN QUANTISTICA




Comparativa run classica e quantistica

Comparativa effettuata su 600 episodi, migliorando le prestazioni della rete neurale classica.

- Vista la disparità del numero di episodi dei due metodi, fare una vera e propria comparativa uno a uno risulta difficile.
- Per confrontare direttamente i due approcci, ho cercato di far convergere l'algoritmo classico nello stesso numero di episodi di quello quantistico fissato a 600.
- A tal fine, ho aumentato il numero di neuroni a 600 per ogni strato nascosto e il batch size a 1000.

Comparativa run classica e quantistica

Comparativa effettuata su 600 episodi, migliorando le prestazioni della rete neurale classica.



Conclusioni

- Performance del RL Classico: La convergenza avviene in circa 6.500 episodi con una ricompensa media di -80 ± 10 .
- Performance del RL Quantistico: Convergenza molto più veloce, in circa 500 episodi, ma con minore stabilità e performance peggiore, ottenendo una ricompensa media di -175 ± 35 .

Conclusioni

- Performance del RL Classico: La convergenza avviene in circa 6.500 episodi con una ricompensa media di -80 ± 10 .
- Performance del RL Quantistico: Convergenza molto più veloce, in circa 500 episodi, ma con minore stabilità e performance peggiore, ottenendo una ricompensa media di -175 ± 35 .
- Su un numero di episodi limitato a 600, l'algoritmo di RL classico non è in grado di performare in maniera adeguata, mostrando in trend instabile e senza segni di convergenza.

Conclusioni

- Performance del RL Classico: La convergenza avviene in circa 6.500 episodi con una ricompensa media di -80 ± 10 .
- Performance del RL Quantistico: Convergenza molto più veloce, in circa 500 episodi, ma con minore stabilità e performance peggiore, ottenendo una ricompensa media di -175 ± 35 .
- Su un numero di episodi limitato a 600, l'algoritmo di RL classico non è in grado di performare in maniera adeguata, mostrando in trend instabile e senza segni di convergenza.

Prospettive future

Conclusioni

- Performance del RL Classico: La convergenza avviene in circa 6.500 episodi con una ricompensa media di -80 ± 10 .
- Performance del RL Quantistico: Convergenza molto più veloce, in circa 500 episodi, ma con minore stabilità e performance peggiore, ottenendo una ricompensa media di -175 ± 35 .
- Su un numero di episodi limitato a 600, l'algoritmo di RL classico non è in grado di performare in maniera adeguata, mostrando in trend instabile e senza segni di convergenza.

Prospettive future

- Implementare l'algoritmo RL Quantistico sui dispositivi IBM, per valutare le performance in un contesto reale e poterlo allenare su un numero maggiore di episodi.
- Analizzare le sfide e i punti di forza del modello quantistico in condizioni reali contribuirà a migliorare sia gli algoritmi di RL quantistico sia l'hardware quantistico.



Grazie per
l'attenzione!